```
Matrices y vectores aleatorios
1.
 X = matrix(c(1, 6, 8, 4, 2, 3, 3, 6, 3), ncol = 3)
      [,1] [,2] [,3]
 ## [1,] 1 4 3
 ## [2,] 6 2 6
 ## [3,] 8 3 3
 bX = X %*% c(1, 1, 1)
 cX = X %*% c(1, 2, -3)
 A = cbind(bX, cX)
         [,1] [,2]
 ## [1,] 8 0
 ## [2,] 14 -8
 ## [3,] 14 5
a)
 bX_mu = mean(bX)
 cX_mu = mean(cX)
 bX_var = var(bX[,1])
 cX_var = var(cX)
 cov = cov(bX[,1], cX[,1])
 cat("Media de b'X:", bX_mu, "\n")
 ## Media de b'X: 12
 cat("Media de c'X:", cX_mu, "\n", "\n")
 ## Media de c'X: -1
 cat("Varianza de b'X:", bX_var, "\n")
 ## Varianza de b'X: 12
 cat("Varianza de c'X:", cX_var, "\n", "\n")
 ## Varianza de c'X: 43
 ##
 cat("Covarianza:", cov, "\n")
 ## Covarianza: -3
b)
 covA = cov(A)
 bX_det = det(covA)
 cat("Determinante de cov_A(S):", bX_det, "\n")
 ## Determinante de cov_A(S): 507
c)
 cat("Matriz de Varianzas-Covarianzas:", covA, "\n")
 ## Matriz de Varianzas-Covarianzas: 12 -3 -3 43
d)
 e = eigen(covA)
 ## eigen() decomposition
 ## $values
 ## [1] 43.28765 11.71235
 ##
 ## $vectors
                [,1]
 ## [1,] -0.09544671 -0.99543454
 ## [2,] 0.99543454 -0.09544671
e)
Son independientes puesto que ambos pesos en los coeficientes contribuyen para poder obtener Y.
 plot(bX, cX, xlim = c(-25, 25), ylim = c(-15, 15))
 x11 = seq(0, 100, 100)
 x12 = e\$vectors[1,1] / e\$vectors[2,1] * x11
 x21 = seq(0, 100, 100)
 x22 = e$vectors[1,1] / e$vectors[1,2] * x21
 abline(x11,x12)
 abline(x21,x22)
     10
     2
     -5
     -10
     -15
                  -20
                               -10
                                             0
                                                          10
                                                                       20
                                            bX
2.
 library(MVN)
 x = rnorm(100, 10, 2)
 y = rnorm(100, 10, 2)
 datos = data.frame(x,y)
 mvn(datos, mvnTest = "hz", multivariatePlot = "persp")
 ## $multivariateNormality
                      HZ p value MVN
 ## 1 Henze-Zirkler 0.3575401 0.8869578 YES
 ## $univariateNormality
                 Test Variable Statistic p value Normality
 ## 1 Anderson-Darling
                                    0.1940
                                             0.8907
 ## 2 Anderson-Darling
                                    0.2806
                                              0.6354
 ##
 ## $Descriptives
                               Median
                                                             25th
                                                                     75th
              Mean Std.Dev
 \#\#\ \times\ 100\ 9.979267\ 1.843290\ 10.045121\ 5.501237\ 13.99113\ 8.726564\ 11.33220
 ## y 100 9.732361 2.023101 9.847664 5.060731 14.44824 8.400162 10.94706
             Skew Kurtosis
 ## x -0.16402519 -0.5185468
 ## y 0.05596624 -0.3573964
 mvn(datos, mvnTest = "hz", multivariatePlot = "contour")
     12
     10
     \infty
     9
                6
                                              10
                                                              12
                                                                              14
                                             Χ
 ## $multivariateNormality
               Test
                           HZ p value MVN
 ## 1 Henze-Zirkler 0.3575401 0.8869578 YES
 ## $univariateNormality
                  Test Variable Statistic p value Normality
 ## 1 Anderson-Darling x 0.1940 0.8907
 ## 2 Anderson-Darling
                                    0.2806 0.6354
 ##
 ## $Descriptives
              Mean Std.Dev Median
                                           Min
 \#\#\ x\ 100\ 9.979267\ 1.843290\ 10.045121\ 5.501237\ 13.99113\ 8.726564\ 11.33220
 ## y 100 9.732361 2.023101 9.847664 5.060731 14.44824 8.400162 10.94706
             Skew Kurtosis
 ## x -0.16402519 -0.5185468
 ## y 0.05596624 -0.3573964
Viendo las funciones, tenemos un diagrama que ofrece una distribución de la probabilidad de una variable en la superficie de tres dimensioens.
Podemos ver como se relacionan las variables entre si. Tambien hay una que muestra como se comporta la distribución en cuanto a una normal
multivariable.
3.
 n = 10 #Cantidad de datos
 x1 = c(1,2,3,3,4,5,6,8,9,11) #Años
 x2 = c(18.95, 19.00, 17.95, 15.54, 14.00, 12.95, 8.94, 7.49, 6.00, 3.99) #Precio
 X = cbind(x1, x2) #DF
 Xbar = colMeans(X) #Media
 S = cov(X) # Covarianza
 Sinv = solve(S)
a)
 plot(x1, x2) # Diagrama de dispersión
     15
                                0
                                      0
     10
                                                          0
     2
                                                                              0
                  2
                                                          8
                                             6
                                                                       10
                                            x1
b)
Es visible que conforme x1 crece, x2 disminuye por lo que la covarianza es negativa.
c)
 d = mahalanobis(X, colMeans(X), cov(X)) #Distancia de Mahalanobis
 ## [1] 1.8753045 2.0203262 2.9009088 0.7352659 0.3105192 0.0176162 3.7329012
 ## [8] 0.8165401 1.3753379 4.2152799
d)
 library(ellipse)
 ## Attaching package: 'ellipse'
 ## The following object is masked from 'package:graphics':
 ##
 ##
        pairs
 elps = t(t(ellipse(S, level=0.85, npoints=1000))+Xbar)
 plot(X[,1],X[,2],type="n")
 index = d < qchisq(0.5, df=p)
 text(X[,1][index],X[,2][index],(1:n)[index],col="blue")
 text(X[,1][!index],X[,2][!index],(1:n)[!index],col="red")
 lines(elps,col="blue")
     15
                                      6
X[, 2]
     10
     5
                  2
                                             6
                                                          8
                                                                       10
                                           X[, 1]
e)
 names(d) = 1:10
 sort(d)
                                          8
                                                              1
 \#\#\ 0.0176162\ 0.3105192\ 0.7352659\ 0.8165401\ 1.3753379\ 1.8753045\ 2.0203262\ 2.9009088
            7
 ## 3.7329012 4.2152799
 qqplot(qchisq(ppoints(500),df=p), d, main="",
 xlab="Theoretical Quantiles", ylab="Sample Quantiles")
 qqline(d, distribution=function(x){qchisq(x,df=p)})
     3
     2
                     2
                               4
                                                  8
                                                           10
                                                                     12
                                                                               14
                                    Theoretical Quantiles
f)
Concluyendo con los resultados de la parte b y c, los datos son aproximadamente normales en dos dimensiones. Se puede observar como los
datos se aproximan a la linea teórica de una normal.
```

act\_Matrices&Vectores

Carlos David Contreras Chacon

2022-10-05